

基于字符相似性网络的垃圾文本检测实验报告

1. 算法设计思路

1. 整体思路

算法的整体思路是：首先处理输入文本，去掉非法字符和停用词。随后对字符进行统计和编码，构建字符相似性网络，生成 Word2Vec 向量、字符向量和句子向量，再完成训练和测试。在本算法中，使用 torch 重构 Word2Vec 向量、字符向量和句子向量的生成。

2. 数据读取与处理

1. 去除非法字符。使用正则表达式匹配所有非中文字符、非英文字符、非数字和非空格字符，将这些字符替换为空字符串，即去除这些非法字符。此外，还要去掉每条文本开头和结尾的空白字符。
2. 去除停用词。停用词是文本处理中被认为在句子中频繁出现但不携带有用信息的词汇。在本算法中，加载停用词表，对每条文本中的每个字符，判断它是不是停用词。如果是停用词，则跳过该字符。最后，将非停用词的字符重新连接成一条文本。

3. 生成 Word2Vec 向量、字符嵌入向量、句子嵌入向量

1. 生成 Word2Vec 向量。Word2Vec 向量将每个词映射到一个高维向量空间，其中语义相近的词会被映射到相近的位置。在本算法中使用 Skip-gram 的方法训练 Word2Vec 向量。

首先，建立一个词汇表，统计词汇表中每个词的出现频次，计算负采样分布并标准化为概率分布。随后，以每个字符为中心词，收集中心词和它的上下文词对，用于后续训练。

训练使用的模型由两个嵌入层组成。一个 `emb_in` 层将中心词索引转换为词向量，一个 `emb_out` 层将上下文词索引转换为词向量。优化器使用 Adam 优化器，学习率 0.002。

在训练时，在一个 batch 中，对每个正样本中心词，首先获得上下文词的词向量，计算每个正样本中心词和上下文词的词向量的点积，获得正样本的损失。随后，使用之前生成的负采样概率分布随机选取负样本，得到负样本的词向量、负样本与中心词的点积，获得负样本的损失。用

于反向传播的参数更新的总损失是正样本损失与负样本损失的负值之和，这样可以最大化正样本得分、最小化负样本得分。
最后，从 `emd_in` 层中获得每个词的词向量。

2. 生成字符向量。在 **Word2Vec** 向量、字符计数和相似性网络的基础上，生成字符向量。对每个字符，首先与这个字符相似的字符的索引，收集这些相似的字符的 **Word2Vec** 向量，并根据这些字符出现的频次计算加权平均，得到这个字符的字符向量。
3. 生成句子向量。句子向量可以把文本信息以一种压缩且高效的方式进行表示。我们可以利用句子向量之间的距离判断句子之间的相似性。在本任务中，可以通过这种方法让模型找到垃圾文本特有的模式和特征。在每条文本中，对每个字符的字符向量进行堆叠，得到一个形状为（文本长度，字符向量维度）的矩阵。随后，通过计算相似度矩阵和 **Softmax** 处理，获得一个表示每个字符与其他字符之间的相对重要性的权重矩阵。最后，对字符向量加权求和再除以维度，得到句子向量。

4. 训练与预测

在实验中，我们使用了两种方法来进行训练和预测。

第一种方法是单纯使用逻辑回归方法来训练。

第二种方法是，在算法中使用 **XGBoost** 分类器来进行训练、预测和评估。

XGBoost 分类器是一种基于梯度提升树的方法。训练开始时，**XGBoost** 使用一个简单的预测值初始化模型。在每一轮训练中，模型计算当前预测值与实际标签之间的误差，再基于误差训练一课新的决策树，将新的决策树添加到当前模型中，形成新的模型。本实验中使用逻辑回归函数进行训练。

5. 评估

算法中采用的评估方法有混淆矩阵和分类报告。

混淆矩阵是一种常见的分类模型评估方法，其中包括四个值：**TP**（正确预测为正类的样本数），**TN**（正确预测为负类的样本数），**FP**（错误预测为正类的样本数），**FN**（错误预测为负类的样本数）。

分类报告提供了 Precision、Recall、F1-Score、Support 四种评估指标，可以显示模型的预测精确率、召回率、二者的调和平均数，以及每个类别的真实样本数。实验中将分类报告制作成表格展示。

2. 算法任务

垃圾文本是指垃圾邮件、广告等内容不符合正常标准的文本。

本实验中需要完成的是垃圾文本检测任务，目标是尽可能准确地分类垃圾文本和正常文本。

算法的输入是一个纯文本文件，文件的每一行是一条文本。算法输出是文本的识别结果，标签 1 表示这条文本是垃圾文本。

3. 实验结果

1. 逻辑回归基本性能

混淆矩阵：
[[2003 497]
[206 5298]]

分类报告：

	precision	recall	f1-score	support
0	0.907	0.801	0.851	2500
1	0.914	0.963	0.938	5504
accuracy			0.912	8004
macro avg	0.910	0.882	0.894	8004
weighted avg	0.912	0.912	0.911	8004

图 3.1 分类报告




图 3.2 逻辑回归分类的 ROC 曲线

2. 分类结果可解释性分析




图 3.3 逻辑回归单样本的 SHAP 值分析

3. 错分类结果分析:




图 3.4 句子向量 T-SNE 分析




图 3.5 误分类文本 a---粤语文本

#7 | idx=3165 | true=1 pred=0 prob=0.001
文本: 中國移動香港:「特選客戶限時優惠, 每月加\$w升級至b服務計劃b, 速度更快! 數據更多! 輸入「t」回覆此短訊完成登記, e天內回覆有效! 現升級至y服務計劃k(可用於p/pl網絡), 月壽只需\$z, 並豁免每月行政費(您正使用計劃為j,e全速!, 上月月壽為\$z, 上月行政費為\$z), 再送s標準電影組合及o禮券。首s數據(可用於1/1網絡), 其後無限限速s數據, 及每月s大灣區數據, m個月合約, 成功升級後新合約的有效期間有服務計劃合約的。即輸入「i」回覆此短訊完成登記, 請留意此登記即被視作閣下同意升級及增的安排, 同時已閱讀及接納閣下內(q://r.u/cd)的條款及細則並受其約束, 而服務計劃將於成功升級後即時生效。查詢x/取消x 中國移動香港:「特選客戶限時優惠, 每月加\$w升級至b服務計劃b, 速度更快! 數據更多! 輸入「t」回覆此短訊完成登記, e天內回覆有效! 現升級至y服務計劃k(可用於p/pl網絡), 月壽只需\$z, 並豁免每月行政費(您正使用計劃為j,e全速!, 上月月壽為\$z, 上月行政費為\$z), 再送s標準電影組合及o禮券。首s數據(可用於1/1網絡), 其後無限限速s數據, 及每月s大灣區數據, m個月合約, 成功升級後新合約的有效期間有服務計劃合約的。即輸入「i」回覆此短訊完成登記, 請留意此登記即被視作閣下同意升級及增的安排, 同時已閱讀及接納閣下內(q://r.u/cd)的條款及細則並受其約束, 而服務計劃將於成功升級後即時生效。查詢x/取消x
/home/panyi/miniconda3/envs/ai/lib/python3.12/site-packages/shap/explainers/_linear.py:99: FutureWarning: The feature_perturbation option is now deprecated in favor of using the appropriate masker (maskers.Independent, maskers.Partition or maskers.Impute).
warnings.warn(wmsg, FutureWarning)

Estimating transforms: 100% 1000/1000 [00:10<00:00, 94.80it/s]




图 3.6 误分类文本 b---粤语文本

#3 | idx=1237 | true=1 pred=0 prob=0.000
文本: 0. 党的建设伟大工程: 毛泽东在《共产党人发刊词》中提出的关于党的建设的著名论述。把党的建设提高到“伟大的工程”的高度, 表明了党对加强自身建设重要性的认识更加自觉和深刻。8. “自己动手, 丰衣足食”: 抗日战争时期, 党领导抗日军民加强根据地经济建设, 开展大生产运动中提出的动员口号。通过大生产运动, 各根据地度过了严重的经济困难, 为抗日战争及新民主主义革命的胜利奠定了物质基础。-六合法院机关党委 0. 党的建设伟大工程: 毛泽东在《共产党人发刊词》中提出的关于党的建设的著名论述。把党的建设提高到“伟大的工程”的高度, 表明了党对加强自身建设重要性的认识更加自觉和深刻。8. “自己动手, 丰衣足食”: 抗日战争时期, 党领导抗日军民加强根据地经济建设, 开展大生产运动中提出的动员口号。通过大生产运动, 各根据地度过了严重的经济困难, 为抗日战争及新民主主义革命的胜利奠定了物质基础。-六合法院机关党委
/home/panyi/miniconda3/envs/ai/lib/python3.12/site-packages/shap/explainers/_linear.py:99: FutureWarning: The feature_perturbation option is now deprecated in favor of using the appropriate masker (maskers.Independent, maskers.Partition or maskers.Impute).
warnings.warn(wmsg, FutureWarning)

Estimating transforms: 100% 1000/1000 [00:10<00:00, 94.09it/s]




图 3.7 误分类文本 c---噪声文本

4. 使用 XGBoost 分类器的性能分析:

混淆矩阵:

```
[[2271 229]
 [ 153 5351]]
```

指标表格:

	0	1	accuracy	macro avg	weighted avg
precision	0.9369	0.959	0.9523	0.9479	0.9521
recall	0.9084	0.9722	0.9523	0.9403	0.9523
f1-score	0.9224	0.9655	0.9523	0.944	0.9521
support	2500.0	5504.0	0.9523	8004.0	8004.0

图 3.8 XGBoost 性能分析表

5. XGBoost 分类器对逻辑回归错误分类样本的反应:



图 3.9 XGBoost 解释性分析

4. 结果分析

1. 逻辑回归分类性能分析

根据图 3.1 可知经过字符相似性网络的提升较之无字符相似性网络提升了 50% 的准确率,从混淆矩阵中可见对角元素占主要位置,性能较好(由于我采用 torch 对 cpu 版的 word2vec 进行重构,此处精度较之下降了 3%,但是效率方面,训练时间由原来的 1h 到目前的秒级完成)

从图 3.2 所示 AUC 曲线可以看出随着真负类的增加,真正类也相应增加,auc 曲线呈现收敛趋势,这是一个性能极好的分类器

2. 逻辑回归分类的可解释性分析:

采用 SHAP 方法可视化单样本各个维度的贡献,并找出各个维度对应的字词在原句里标红。

从图 3.3 所示, 维度 34 / 47 / 44 / 31 ... 都被形似或音似的“广告变体字”强激活:

綫娛冻信誉枰苔、宋代替送...

这些维度也是 SHAP 瀑布图中粉红条贡献正向最大的, 所以模型将整句判为垃圾。

高亮出的字符「綫、娛、冻、枰、苔、宋」正是广告常用的同形/同音替换字,进一步验证了 CSN 嵌入确实把这些“伪装字符”拉成了与真实广告词相近的向量,从而成功捕捉到了垃圾特征。

3. 1 T-SNE 结果分析:

1. 语料在嵌入空间的大体分布

左下角蓝色块 与 右上/右侧红色块 大体分离——

说明句向量对 正常 vs. 垃圾 的整体可分性良好

整体呈 “↙-↗ 两臂” 形状: 句向量经 t-SNE 压到 2 维后保留了主要的“语义主方向”。

2. 过渡带 = 决策难点

中间黑圈密集的“混色走廊”正是 0/1 样本相互靠近的地带——

嵌入空间里两类语义混杂，模型边界最难画好。

误判几乎全部集中在此区，说明错误是“有理可循”的，而不是随机。

3. 可能的改进方向

观察	推论	可尝试措施
0/1 仍有较大重叠	嵌入维度不足捕捉细粒度差异	- 增大 w2v 维度 d - 提升 sim_thr，让相似网络更稠密 - 句向量添加 词级 或 位置编码
误判多在蓝-红接壤	判错多为“边界样本”	- 采用 边际损失 / class-weight 加强边缘学习 - 在该走廊附近做 主动学习：手动复核再回灌
孤立少量红点混入蓝块	垃圾文本里出现了与正常文本极相似的句式	- 检查这些红点原句：可能是“合法词+广告数字”组合； - 在特征层增加 数字正则化（如金额/QQ/微信号特殊处理）

3.2 单例样本分析:

1.根据样本 a 和 b 可知,词向量对于粤语表述可能因为不具备预训练的知识从而导致判断垃圾文本为正常文本,因为粤语中的语气词和表述等和普通话存在差异。

---> 可能的优化方向:将 Word2Vec 生成词向量部分改为使用有预训练知识的 bert 进行

2. 样本 c 明显不是垃圾文本，但是被标注为垃圾文本,可能该数据集存在噪声或者标注错误的问题，这也是现实中很常碰到的问题，因此我们需要一个更鲁棒的分类器

---> 已实现的优化方向:改为使用 XGBoost 模型作为分类器

4.XGBoost 性能分析:

由 3.8 可知 XGBoost 在基于原有的 word2vec(torch)版的基础上比逻辑回归提高了 4%的分类性能,比原始实验高出 1%的准确率,提高了鲁棒性。

另外从 3.9 可知,原来被逻辑回归判定为 0 可能性的垃圾文本目前提高到了 99,表现出更强的鲁棒性。

5. 主要算法代码及说明

read_data:

将原始文件分割为标签和文本部分

clean_text:

使用正则表达式清洗文本中的非中文部分(由于去掉大量标点,这个举动可能导致识别不出某些垃圾文本)

tokenize_and_remove_stopwords:

将文本 token 化并移除停用词

count_chinese_characters:

计算汉字出现次数,为计算相似矩阵做好准备

compute_sim_mat:

计算相似性矩阵

generate_w2v_vectors:

利用 Word2Vec 生成词向量

generate_char_vectors:

从词向量剖析出字符级向量

generate_sentence_vectors:

根据字符向量生成句子向量

train_test_split:

测试集和训练集分割

spam_classification:

逻辑回归分类并作初步评估

Evaluation

进一步评估

6. 创新性:

1. 如 3 和 4 所示,采用 torch 重构 Word2Vec,字符向量生成和句子向量生成部分,使得训练时间由原来的 1h30min 左右减少至目前的秒级完成,虽然损失部分精度,但是大大提高效率,符合这项任务的实时性。
- 2.采用 XGBoost 替换逻辑回归分类器,获得了 4%准确率的提升,鲁棒性提高。