

小型领域知识图谱构建

实验原理

领域知识图谱：

知识图谱包括通用知识图谱和领域知识图谱。通用知识图谱是面向全领域的，要包括广泛的常识，主要应用于互联网搜索。领域知识图谱是针对特定行业或领域的知识图谱，更强调各个实体之间的联系，更具有专业性。

实验过程

数据集

采用了2020年中国排名前100大学信息的数据集，数据集地址如下：

[2020年中国排名前一百大学知识图谱 - 数据集 - 开放知识图谱]

(<http://data.openkg.cn/dataset/2020>)

提取实体和关系

安装 `spacy`，并加载中文模型。

```
# 加载中文模型
nlp = spacy.load("zh_core_web_sm")
```

使用两个空列表存储实体和关系信息，实体包括序号之外的每一列。

考虑到不同大学的创建时间和主管部门可能相同，也可能不同，因此在关系中包括中文名与创建时间之间的关系、中文名与主管部门之间的关系。

又考虑到大家在网络讨论时经常使用大学的简称，因此在关系中包括中文名与简称之间的关系。

由于这个数据集有100行数据，数据量太大，可能会导致可视化方面的问题，故随机选择20条数据。

导入图数据库

首先，下载安装Neo4j。

安装后无法打开。找到运行日志，打开后发现报错 `[error] Protocol Manager type error: url must be string. url = undefined`

经过搜索，没有找到有效解决方案。我自己尝试了修改安装路径、以管理员身份运行、关闭电脑防火墙、断网，依然无法打开。

因此，我决定改用ArangoDB作为替代。

首先，需要安装docker，才能在windows系统下使用ArangoDB。docker安装后在打开时报错，查阅博客得知，需要安装Windows Subsystem for Linux。

在安装Windows Subsystem for Linux 时，我又遇到了安装后依然显示“没有可用的本地分发”问题。使用命令 `ws1 --status` 得知，我的计算机配置不支持使用WSL1和WSL2。

继续尝试使用neo4j，我发现可以使用社区版，于是安装了社区版。

初次使用报错 找不到或无法加载主类 `org.neo4j.server.startup.Neo4jCommand`，经过查询得知是JAVA17与neo4j不兼容，于是改用JAVA23。

```
C:\Users\Administrator>neo4j console
Directories in use:
home:           E:\neo4j-community-2025.02.0
config:         E:\neo4j-community-2025.02.0\conf
logs:           E:\neo4j-community-2025.02.0\logs
plugins:        E:\neo4j-community-2025.02.0\plugins
import:         E:\neo4j-community-2025.02.0\import
data:           E:\neo4j-community-2025.02.0\data
certificates:   E:\neo4j-community-2025.02.0\certificates
licenses:       E:\neo4j-community-2025.02.0\licenses
run:            E:\neo4j-community-2025.02.0\run
Starting Neo4j.
WARNING! You are using an unsupported Java runtime.
* Please use Java(TM) 21 to run Neo4j.
* Please see https://neo4j.com/docs/ for Neo4j installation instructions.
2025-03-16 08:36:58.244+0000 INFO  Logging config in use: File 'E:\neo4j-community-2025.02.0\conf\user-logs.xml'
2025-03-16 08:36:58.252+0000 INFO  Starting...
2025-03-16 08:36:59.086+0000 INFO  This instance is ServerId{a358991a} (a358991a-4405-4b64-be42-03edd0d86e6d)
2025-03-16 08:36:59.987+0000 INFO  ===== Neo4j 2025.02.0 =====
2025-03-16 08:37:02.684+0000 INFO  Anonymous Usage Data is being sent to Neo4j, see https://neo4j.com/docs/usage-data/
2025-03-16 08:37:02.732+0000 INFO  Bolt enabled on localhost:7687.
2025-03-16 08:37:03.286+0000 INFO  HTTP enabled on localhost:7474.
2025-03-16 08:37:03.286+0000 INFO  Remote interface available at http://localhost:7474/
2025-03-16 08:37:03.286+0000 INFO  id: 3B9292915F8F587186222897271B7C95C1F08617DDCA28DD2A276EB15DD7AA97
2025-03-16 08:37:03.286+0000 INFO  name: system
2025-03-16 08:37:03.286+0000 INFO  creationDate: 2025-03-16T08:30:36.989Z
2025-03-16 08:37:03.286+0000 INFO  Started.
```

成功运行了NEO4J。



实验结果

关系提取结果（部分）

```
实体:
{'Chinese_Name': '湖南大学', 'English_Name': 'Hunan University', 'Abbreviation': '湖大·HNU', 'Establishment_Time': '1903年', 'Type': '综合类（研究型大学）', 'Superv':
{'Chinese_Name': '扬州大学', 'English_Name': 'Yangzhou University', 'Abbreviation': '扬大', 'Establishment_Time': '1902年', 'Type': '综合', 'Supervisory_Departme
{'Chinese_Name': '复旦大学', 'English_Name': 'Fudan University', 'Abbreviation': '复旦·FUDAN', 'Establishment_Time': '1905年（乙巳年）6月29日', 'Type': '综合', 'Sup
{'Chinese_Name': '东华大学', 'English_Name': 'Donghua University', 'Abbreviation': 'DHU[1]\xa0', 'Establishment_Time': '1951年', 'Type': '综合', 'Supervisory_Dej
{'Chinese_Name': '太原理工大学', 'English_Name': 'Taiyuan University of Technology', 'Abbreviation': '太原理工（TYUT）', 'Establishment_Time': '1902年', 'Type': '工
{'Chinese_Name': '齐鲁工业大学（山东省科学院）', 'English_Name': 'Qilu University of Technology (QLU)', 'Abbreviation': '齐鲁工大', 'Establishment_Time': '1948年', '
{'Chinese_Name': '东南大学', 'English_Name': 'Southeast University\xa0', 'Abbreviation': '东大（SEU）', 'Establishment_Time': '1902年', 'Type': '综合类', 'Supervi
{'Chinese_Name': '燕山大学', 'English_Name': 'Yanshan University', 'Abbreviation': '燕山（YSU）[5]\xa0', 'Establishment_Time': '1920年', 'Type': '综合性大学[3]\xa0
```

```
关系:
{'subject': '湖南大学', 'object': '1903年', 'relationship': '创办时间'}
{'subject': '湖南大学', 'object': '中华人民共和国教育部', 'relationship': '主管部门'}
{'subject': '湖南大学', 'object': '湖大·HNU', 'relationship': '简称'}
{'subject': '扬州大学', 'object': '1902年', 'relationship': '创办时间'}
{'subject': '扬州大学', 'object': '江苏省', 'relationship': '主管部门'}
{'subject': '扬州大学', 'object': '扬大', 'relationship': '简称'}
{'subject': '复旦大学', 'object': '1905年（乙巳年）6月29日', 'relationship': '创办时间'}
{'subject': '复旦大学', 'object': '中华人民共和国教育部', 'relationship': '主管部门'}
{'subject': '复旦大学', 'object': '复旦·FUDAN', 'relationship': '简称'}
{'subject': '东华大学', 'object': '1951年', 'relationship': '创办时间'}
{'subject': '东华大学', 'object': '中华人民共和国教育部[1]\xa0', 'relationship': '主管部门'}
{'subject': '东华大学', 'object': 'DHU[1]\xa0', 'relationship': '简称'}
{'subject': '太原理工大学', 'object': '1902年', 'relationship': '创办时间'}
{'subject': '太原理工大学', 'object': '山西省', 'relationship': '主管部门'}
{'subject': '太原理工大学', 'object': '太原理工（TYUT）', 'relationship': '简称'}
{'subject': '齐鲁工业大学（山东省科学院）', 'object': '1948年', 'relationship': '创办时间'}
{'subject': '齐鲁工业大学（山东省科学院）', 'object': '山东省', 'relationship': '主管部门'}
{'subject': '齐鲁工业大学（山东省科学院）', 'object': '齐鲁工大', 'relationship': '简称'}
{'subject': '东南大学', 'object': '1902年', 'relationship': '创办时间'}
{'subject': '东南大学', 'object': '中华人民共和国教育部', 'relationship': '主管部门'}
{'subject': '东南大学', 'object': '东大（SEU）', 'relationship': '简称'}
{'subject': '燕山大学', 'object': '1920年', 'relationship': '创办时间'}
```

知识图谱构建结果



图中的实体：大学中文名、所属部门、简称。

图中的关系：中文名和简称之间的关系，中文名和所属部门之间的关系。