

# 电影评论情感分类

## 实验原理

### 逻辑回归

逻辑回归是一种监督学习方法，主要用于解决二分类问题。它使用sigmoid函数进行运算结果与标签之间的映射，使用交叉熵或者均方误差作为损失函数。

### SVM

SVM的核心思想是通过优化一个凸二次规划问题，来在特征空间中找到最佳的超平面。它的基本模型是定义在特征空间上间隔最大的线性分类器。间隔是指点到超平面的间隔，间隔最大是指使得超平面和支持向量（距离分类超平面最近的那些样本点）之间的距离最大。

### IMDB数据集

IMDB数据集包括了50000条有明显偏向的影评，其中训练集和测试集各占一半。在keras自带的数据源中，影评数据用整数编码表示，在使用时需要先映射为单词。

## 实验过程

### 数据处理

```
(x_train, y_train), (x_test, y_test) = tf.keras.datasets.imdb.load_data()

word2id = tf.keras.datasets.imdb.get_word_index()
id2word = dict([(value, key) for (key, value) in word2id.items()])
comments_word = lambda word: ' '.join([id2word.get(i - 3, '?') for i in word])
x_train_word = [comments_word(comment) for comment in x_train]
x_test_word = [comments_word(comment) for comment in x_test]
```

首先，引入IMDB数据集，使用原本的训练集与测试集划分。

由于keras的IMDB数据源中，数据使用编码形式表示，因此要建立id2word字典，将数据转换成自然语言形式。

```
vectorizer = TfidfVectorizer(stop_words='english', max_features=3000)
X_train = vectorizer.fit_transform(x_train_word)
X_test = vectorizer.fit_transform(x_test_word)
```

随后，使用TF-IDF进行特征提取。

## 模型应用

```
logic_start = time.time()
logic_model = LogisticRegression()
logic_model.fit(X_train, y_train)
logic_predict = logic_model.predict(X_test)
logic_acc = accuracy_score(y_test, logic_predict)
logic_end = time.time()
print(f"Logistic Regression Accuracy: {logic_acc:.2f}, runtime:{logic_end - logic_start}")

svm_start = time.time()
svm_model = SVC(kernel='linear')
svm_model.fit(X_train, y_train)
svm_acc = svm_model.score(X_test, y_test)
svm_end = time.time()
print(f"SVM Accuracy: {svm_acc}, runtime: {svm_end - svm_start}")
```

搭建逻辑回归与SVM模型，进行训练和测试，输出测试集准确率和总运行时间。

由于使用高斯核函数时运行时间过长，SVM核函数使用线性核函数。

## 实验结果

```
Logistic Regression Accuracy: 0.58, runtime:0.2215418815612793
SVM Accuracy: 0.57684, runtime: 449.59432339668274

Process finished with exit code 0
```

逻辑回归和SVM的准确率相似，但逻辑回归的运行时间远低于SVM。