

图文多模态问答

实验原理

VQA

VQA的全称是Visual Question Answering，是指让机器观看图像，并回答关于图像内容的自然语言问题。这是多模态理解领域的一个核心任务，要求模型能够理解图像内容，并能将图像与自然语言联系起来。

一个VQA模型架构通常包括：

1. 图像编码器：用于从输入图像中提取视觉特征，一般是一个CNN网络。
2. 文本编码器：用于从输入的自然语言问题中提取文本特征，一般是一个RNN网络。
3. 多模态融合模块：现在一般使用注意力机制来学习图像特征与文本特征之间的关系。
4. 答案预测模块：预测最终答案。常见的答案预测方法有分类（预定义一个答案词汇表，模型从中选择概率最高的词作为答案），生成（使用RNN或Transformer生成自然语言答案）。

ViLT模型

ViLT模型是一种不需要目标检测的多模态学习框架，它把每个模态的特征抽取部分做了最小化，把主要的计算量都放在了特征融合部分。特征融合部分以图像和文本的表征的序列作为输入，通过每个Transformer Block对模态之间和模态内部的信息进行交互，输出交互之后的特征序列。

实验过程

首先，安装transformers包，引入Vilt模型。

随后，加载模型和图片，执行问答任务。

```
processor = ViltProcessor.from_pretrained("dandelin/vilt-b32-finetuned-vqa")
model = ViltForQuestionAnswering.from_pretrained("dandelin/vilt-b32-finetuned-vqa")
image = Image.open("question.jpg")

question = "What's in the room?"
inputs = processor(text=question, images=image, return_tensors="pt")
outputs = model(**inputs)
```

获取预测最大概率的索引，通过id2label映射得到最终答案

```
answer_idx = outputs.logits.argmax(-1).item()
print("答案:", model.config.id2label[answer_idx])
```

实验结果

问题图片如下：



回答:

```
C:\Python312\python.exe E:\学习\Pycharm\VQA\main.py
2025-03-29 11:36:18.063171: I tensorflow/core/util/port
services Alt+8 > 11:36:18.752333: I tensorflow/core/util/port
答案: bed
|
```