

中山大学计算机院本科生实验报告

(2024年春季学期)

课程名称：并行程序设计

批改人：

实验	9-CUDA矩阵乘法	专业	计算机科学与技术
学号	22336203	姓名	沈苇杭
Email	shenwh7@mail2.sysu.edu.cn	完成日期	2025.6.4

实验目的

- 掌握基本的CUDA编程API。
- 掌握使用CUDA编程加速矩阵乘法的方法。
- 分析线程块大小、矩阵规模、访存方式、任务/数据划分方式对CUDA程序性能的影响。

实验过程与核心代码

基础程序

首先，从命令行中获得m、n、k的值，判断它们的值是否满足要求。在满足要求的情况下，分配CPU内存用于存储矩阵，再对两个输入矩阵做随机初始化。

```
double *d_A, *d_B, *d_C;

err1 = cudaMalloc(&d_A, sizeA);
err2 = cudaMalloc(&d_B, sizeB);
err3 = cudaMalloc(&d_C, sizeC);
```

随后，创建指向GPU上内存的指针，在GPU上为三个矩阵分配内存。

```
cudaMemcpy(d_A, A, sizeA, cudaMemcpyHostToDevice);
cudaMemcpy(d_B, B, sizeB, cudaMemcpyHostToDevice);
```

将矩阵A和B复制到GPU上。

```
dim3 threadsPerBlock(16, 16);
dim3 numBlocks((m + threadsPerBlock.x - 1) / threadsPerBlock.x, (k +
threadsPerBlock.y - 1) / threadsPerBlock.y);

cudaEvent_t start, stop;
cudaEventCreate(&start);
cudaEventCreate(&stop);
cudaEventRecord(start);

multiply<<<numBlocks, threadsPerBlock>>>(d_A, d_B, d_C, m, n, k);
cudaMemcpy(C, d_C, sizeC, cudaMemcpyDeviceToHost);
```

定义线程块的维度和网格的维度，创建用于记录时间的CUDA事件。在GPU上并行执行CUDA核函数，并将计算结果从GPU复制回内存。

最后，记录并输出运行时间，释放GPU内存和主机内存，结束程序。

CUDA核函数实现

```
__global__ void multiply(double* A, double* B, double* C, int m, int n, int k) {
    int row = blockIdx.y * blockDim.y + threadIdx.y;
    int col = blockIdx.x * blockDim.x + threadIdx.x;

    if (row < m && col < k) {
        double value = 0;
        for (int i = 0; i < n; ++i) {
            value += A[row * n + i] * B[i * k + col];
        }
        C[row * k + col] = value;
    }
}
```

基础版本的核函数，每个线程计算矩阵中的一个元素。

在实验中，还对核函数进行了优化。首先，尝试了在核函数中修改任务划分方式，让每个线程处理一个2*2的子矩阵，进而减少创建的线程数量，减少创建线程过程中的开销。此外，还使用共享内存减少对全局内存的访问次数，降低内存访问延迟。

实验结果

基础版本核函数

矩阵规模\线程块大小	8*8	16*16	32*32
256	1.46	1.38	1.48
512	8.42	6.75	7.88
1024	52.04	43.96	52.60
2048	411.74	305.95	284.92

修改任务划分方式

矩阵规模\线程块大小	8*8	16*16	32*32
256	2.86	3.09	4.02
512	20.09	21.09	24.93
1024	155.23	113.71	185.92
2048	1244.59	969.26	1051.84

使用共享内存

矩阵规模\线程块大小	8*8	16*16	32*32
256	1.16	0.94	0.91
512	4.79	5.24	4.58
1024	28.36	23.37	20.47
2048	182.25	157.11	120.07

从表中可以看出，在其他条件相同的情况下，矩阵规模越大，运行用时越长。线程块大小过大或过小都会影响程序性能。修改核函数为一次处理一个2*2矩阵会显著降低程序性能。使用共享内存可以显著提升程序性能。

实验感想

在本次实验中，我进一步熟悉了使用CUDA优化矩阵运算，掌握了核函数的不同写法。