

基于 ResNet 模型的细粒度图像分类准确率提升

Abstract

本项目是一个使用 resnet 模型的细粒度图像分类项目。项目在 ResNet 模型的基础上，使用数据增强、微调预训练模型、集成模型、辅助损失函数等训练方法，提升模型的测试准确度，并对模型的正确和错误预测进行分析。

1. Introduction

1.1 任务简介

Fine-grained classification, 即细粒度图像分类，是指将一个大类中的图像分到对应的子类。它和通用图像分类任务的区别在于，图像所属类别的粒度更加精细，分类的难度和挑战都更大。在应用方面，细粒度图像分类可以用于动物物种分类、艺术品风格分类等任务。

1.2 项目简介

本项目是一个使用 resnet 模型的细粒度图像分类项目。在项目中，使用数据增强，批归一化，ensemble model，微调预训练模型，dropout，添加 supervised contrastive loss 等训练技巧训练模型，尝试达到 90%以上的测试准确度，并尝试用训练曲线、样本可视化、混淆矩阵、CAM 热力图等方式对结果进行可视化。

2. Method

2.1 基础模型

本项目使用的基础模型是 ResNet50 模型。它是 ResNet 的较深版本，比 ResNet18 和 ResNet34 性能更好，比 ResNet101, ResNet152 等更深的模型需要的训练时间更短，适合用于探索各种训练技巧。

2.2 数据的基本处理

本项目使用的数据集是 CUB_200_2011 数据集。这是细粒度图像分类领域的经典数据集，包含属于鸟类的 200 个子类别的 11788 张图像，其中 5994 张用于训练，5794 张用于测试。

在本项目中，在训练和测试前会对数据进行基本的处理，对数据转换成的 Pytorch 张量进行标准化操作，消除不同评价指标带来的差异，方便后续处理。

2.3 训练设置

在这里介绍本项目中使用的基本训练设置。项目中使用的优化器是 Adam 优化器，使用的损失函数是交叉熵损失函数，初始学习率 $1e-4$ ，BatchSize = 64，epoch = 100.

2.4 训练技巧

在项目中使用了如下训练技巧提升测试准确度：


1. 数据增强。数据增强是一种对原始数据进行一系列变换和处理，从而生成新的数据，达到扩充数据集的效果。在实验中，我采取了两种进行数据增强的方法。第一种方法是，按照给定的概率，随机地对图像进行上下翻转。第二种方法是，随机从图像中裁剪一个纵横比和面基均在指定区间内随机的区域，并将裁剪下来的区域扩张到原本图像的大小。
2. 批归一化。批归一化是指在每一层的输入中都插入一个归一化层，从而使得在训练中逐渐向两端偏移的非线性层输入重新回到激活函数最敏感的区域。在实验中，ResNet 的 BasicBlock 和 BottleNeck 中都

进行了批归一化。

3. Ensemble Model。Ensemble Model 是一种推理时使用的方法，通过结合多个模型的预测结果，来提高测试准确率。在实验中，我训练了三个不同深度的 ResNet 模型，在推理时使用投票方法获得最终预测结果。
4. 微调预训练模型。微调预训练模型是指，下载已经预训练好的模型，通过微调它的最后几层来让它执行当前的任务。这样做的好处是，可以节约训练资源，节省训练时间。
5. Dropout。Dropout 是一种在训练中随机丢弃神经元的方法，通常用于改善过拟合的情况。在实验中，我在 ResNet 构建每一层的 forward 方法中和最终的全连接层之前都添加了 Dropout。
6. 辅助 Supervised contrastive loss。Supervised contrastive loss 可以使类内嵌入更近，类间嵌入更远。在实验中，我修改了原本搭建的 ResNet 模型，使得新模型的 forward 方法可以返回特征，进而实现计算 Supervised contrastive loss。同时，我引入了参数 `supcon_weight`，用于控制两种损失函数结合时的权重。

3. Experiments

3.1 过拟合



模型的训练准确率达到接近 100%，但测试准确率只有 74.7%，可以看出模型此时过拟合。

3.2 训练技巧


1. 数据增强。在实验 1.1 的基础上，使用随机裁剪的方法进行数据增强，准确率由 74.7%提升至 76.4%；使用随机翻转的方法进行数据增强，准确率由 74.7%提升至 77.2%。由此可见，数据增强对测试准确率有较大的提升。
2. 批归一化。由于原本的项目模型中已经使用了批归一化，因此我测试了删除批归一化之后的版本。删除批归一化后，测试准确率由 74.7%降低至 43.8%。可见，批归一化对模型的准确率有巨大的影响。
3. Ensemble Model。我使用默认的参数另外训练了一个 ResNet 101 和一个 ResNet 152 模型，用这个三个模型的预测结果进行投票，准确率

由 74.7%提升至 79.8%。由此可见，Ensemble Model 对测试准确率有较大的提升。

4. 微调预训练模型。在同样的训练参数设置下进行对比实验，使用预训练模型的测试准确度可以达到 75.0%，不使用预训练模型的测试准确度为 23.4%。由此可见，使用预训练模型对模型准确率有较大的提升。
5. Dropout。在实验 1.1 的基础上使用 Dropout，设置丢弃概率为 0.5，准确率由 74.7%提升至 75.5%。由此可见，Dropout 对测试准确率的提升不大。


3.3 模型可解释性分析

1. 混淆矩阵




由于本项目的任务是多类别分类，在绘制图像时文字重叠，无法清晰地看出具体的分类情况。但图像中的对角线上元素较多，这说明模型的准确率较高。模型非对角线的边缘地区也有一些元素，这说明有部分图像被错误分类了。

2. ROC 曲线



图中显示的大部分类的 AUC 都在 0.98 以上, 说明模型的分类性能较好。

3. 热力图



图中可以看出，模型主要通过鸟的身体上半部分来判断鸟的种类。

3.4 辅助损失函数

添加辅助损失函数前，测试准确率为 74.7%；添加辅助损失后，测试准确率为 74.4%，准确率不升反降，说明辅助损失函数在这个任务上对模型准确率提升的帮助不大。

4. Conclusion

4.1 最终预测结果

最终，在结合使用五种训练技巧后，得到的最高准确率为 79.8%。

4.2 训练技巧

在实验中可以发现，对模型影响最大的训练技巧是批归一化和使用预训练模型。Ensemble model 和数据增强对模型的性能也有一定的提升。

Dropout 对模型性能的影响不大。

4.3 改进方向

虽然模型在整体上分类准确率较高，但仍然有部分测试样本分类错

误的问题。实验的改进方向是，使用更多的方法来缓解模型过拟合，从而提升测试准确率。

5. Reference List

1. 课程 PPT
2. [【论文笔记 1】Supervised Contrastive Learning - 知乎](#)